

GMADL_test

☒ Done

☐

GMADL损失函数测试与改进方案报告

一、测试目标

基于GMADL原始公式（参数：a=100, b=2），系统验证其在不同True Return和Estimated Return组合下的行为特性。

$$L_i = -[\sigma(a \cdot y \cdot \hat{y}) - 0.5] \times |y|^b$$


二、实验设计

测试矩阵

- **True Return：** ±0.1（代表中等波动）
- **Estimated Return：** -1, -0.5, -0.1, -0.01, +0.01, +0.1, +0.5, +1
- **可视化方案：**
 1. 方案B（多子图线图）：4个场景（y = -0.8, -0.1, +0.1, +0.8）
 2. 方案A（热力图）：全参数空间（y ∈ [-1,1], ŷ ∈ [-1,1]）
 3. 方案C（对比实验）：MADL vs GMADL在关键场景
 4. 接下来细化方法：把函数拆解，单独画出sigmoid是如何随预测值变化而变化的。

三、实验结果分析

3.1 多子图线图结果



关键发现：

✓ 方向判断有效性确认

- 在 $x=0$ 处存在清晰的奖惩切换点
- 方向正确时 $\text{Loss} < 0$ （奖励），方向错误时 $\text{Loss} > 0$ （惩罚）
- sigmoid平滑过渡避免了MADL的梯度断裂问题

× 问题1：完全对称性

- 奖励幅度 = 惩罚幅度（如 $y=0.8$ 时， $\hat{y}=+1$ 奖励 ≈ -0.32 ， $\hat{y}=-1$ 惩罚 $\approx +0.32$ ）
- 交易策略中“避免亏损 > 追求盈利”的原则未体现


× 问题2：临界点信号微弱

- 当 $|\hat{y}|$ 接近0时，曲线在 $x=0$ 附近几乎水平
- sigmoid项接近0.5，方向判断信号过弱，模型缺乏学习动力

× 问题3：忽略预测精度

- Loss值仅与 $|y|$ 和方向相关，与 $|\hat{y} - y|$ （预测误差）无关
- $\hat{y}=+0.01$ 和 $\hat{y}=+1$ 在 $y=+0.1$ 时获得相同方向的奖励趋势，未奖励精确预测

3.2 热力图结果



测试结果：

✓ 方向边界清晰

- 对角线 ($y=\hat{y}$ 和 $y=-\hat{y}$) 两侧颜色对比鲜明
- 绿色区域 (奖励) 和红色区域 (惩罚) 分界明确

× 问题4：远离对角线的极端区域惩罚过重


- 右上角/左下角 (方向完全相反) 颜色饱和
- 即使预测方向完全错误，过度惩罚可能导致模型过于保守

× 问题5：沿等 y 线的颜色均匀

- 横向观察 (固定 y , 变化 $\hat{y}$)，同方向区域内颜色几乎一致
- 说明函数未区分"方向正确但误差大"和"方向正确且误差小"

3.3 MADL vs GMADL对比

MADL vs GMADL 对比实验 (a=100, b=2)



对比结论：

✓ GMADL优势：平滑可导

- 小幅上涨场景 (y=+0.01)：GMADL曲线连续，无梯度断裂
- 大幅下跌场景 (y=-0.8)：GMADL惩罚幅度约为MADL的2倍 (通过 $|y|^2$ 放大)

× GMADL局限：未充分利用预测值信息

- MADL在y=+0.01场景下，方向正确时奖励恒定为-0.01
- GMADL在相同场景下，奖励在-0.005左右波动，但未随 $\hat{y}$ 接近y而显著增大

四、核心问题总结

问题类型	具体表现	实际影响
问题1：完全对称性	奖励幅度 = 惩罚幅度 如：y=0.8时， $\hat{y}=+1$ 奖励 ≈ -0.32 ， $\hat{y}=-1$ 惩罚 $\approx +0.32$	无法体现交易策略的风险厌恶偏好；不符合"避免亏损优先于追求盈利"原则
问题2：忽略预测精度	Loss仅与 y 和方向相关，与预测误差 $ \hat{y}-y $ 无关 $\hat{y}=+0.01$ 与 $\hat{y}=+1$ 在y=+0.1时获得相同趋势奖励	无法激励模型提高预测精度；方向正确但误差大的预测未受惩罚
问题3：小预测值信号微弱	当 $ \hat{y} \rightarrow 0$ 时，sigmoid项 ≈ 0.5 ，曲线在x=0附近几乎水平 梯度接近消失	模型可能退化为输出接近0的保守预测；缺乏学习动力
问题4：极端惩罚饱和	方向完全错误时 (y· $\hat{y} \ll 0$)，sigmoid项 $\rightarrow 0$ 或1 Loss接近 $\pm y ^2$ 的上下界	过度惩罚可能导致训练不稳定；梯度爆炸风险；模型过于保守
问题5：参数敏感性	参数a=100决定sigmoid陡度，固定值可能不适应所有场景 小波动与大波动场景需求不同	缺乏自适应性；需要针对不同市场regime手动调参
问题6：梯度不均匀	在 $ y \cdot \hat{y} $ 很小时梯度微弱， $ y \cdot \hat{y} $ 很大时梯度饱和 有效梯度区间窄	训练初期收敛慢；后期可能震荡；难以找到最优解

梯度不均匀 - 解读

问题优先级排序

High:

- 问题2（忽略预测精度）← 核心缺陷，违背损失函数基本原则
- 问题3（小预测值信号弱）← 导致模型退化风险

Medium:

- 问题1（完全对称性）← 领域特性需求
- 问题4（极端惩罚饱和）← 训练稳定性隐患

Low:

- 问题5（参数敏感性）← 工程实践问题
- 问题6（梯度不均匀）← 优化器可部分缓解

五、改进方案设计

目标：让Loss随预测误差 $|\hat{y}-y|$ 缩小而变大，同时保持方向判断清晰

方案1：精度加权型GMADL（推荐）

核心思想： 引入精度奖励因子，方向正确时根据误差大小调整奖励

$$L_i^{new} = -[\sigma(a \cdot y \cdot \hat{y}) - 0.5] \times |y|^b \times \underbrace{\left(1 + \lambda \cdot e^{-\beta|\hat{y}-y|}\right)}_{\text{精度奖励项}}$$

参数:

- λ : 精度奖励强度（建议0.5~2）
- β : 精度敏感度（建议5~20）

优化角度：奖励精度（Reward Accuracy）

- **针对问题2：** 忽略预测精度
- **核心机制：** 在原GMADL基础上叠加 $1 + \lambda \cdot e^{-\beta|\hat{y}-y|}$ 精度项
- **优化维度：** 距离敏感性 - 让Loss随预测值接近真实值而增大
- **作用位置：** 仅在方向正确时生效（乘法增强奖励）

特性:

- 当误差趋近0时，精度奖励项接近 $(1+\lambda)$ ，奖励放大
- 当误差较大时，精度奖励项衰减至1，退化为原GMADL
- **仅在方向正确时** ($\sigma - 0.5 > 0$) 才有精度奖励，保持方向优先

问题：

若只在方向正确前提下具有精度奖励性，方向错误时该如何处理？

方案2：非对称奖惩型GMADL

核心思想： 惩罚系数 > 奖励系数，体现风险厌恶

方向正确时：

$$L_i = -\alpha \cdot [\sigma(a \cdot y \cdot \hat{y}) - 0.5] \times |y|^b$$

方向错误时：

$$L_i = \gamma \cdot [0.5 - \sigma(a \cdot y \cdot \hat{y})] \times |y|^b$$

参数：

- α ：奖励系数（建议0.8~1.2）
- γ ：惩罚系数（建议1.5~3）
- 通常设置 $\gamma > \alpha$ ，如 $\alpha=1, \gamma=2$

优化角度：风险偏好（Risk Preference）

- **针对问题1：** 完全对称性
- **核心机制：** 引入 α （奖励系数）和 γ （惩罚系数），设置 $\gamma > \alpha$
- **优化维度：** 激励不对称性 - 体现"避免损失 > 追求收益"
- **作用位置：** 直接调整整个Loss的系数

特性：

- 方向错误时惩罚加倍
- 符合交易策略中"少亏钱比多赚钱更重要"

问题：

奖励，惩罚系数的设置是否需要根据实际情况找到最优设置？

方案3：自适应阈值型GMADL

核心思想： 对 $|\hat{y}|$ 过小的预测降低奖惩，避免模型输出接近0

$$L_i^{new} = -[\sigma(a \cdot y \cdot \hat{y}) - 0.5] \times |y|^b \times \max(|\hat{y}|, \epsilon)$$

参数：

- ϵ ：最小置信度阈值（建议0.05~0.2）

优化角度：置信度约束（Confidence Constraint）

- **针对问题3：** 小预测值信号微弱
- **核心机制：** 引入 $\max(|\hat{y}|, \epsilon)$ 作为置信度因子
- **优化维度：** 预测勇气 - 惩罚接近0的保守预测
- **作用位置：** 作为整体Loss的缩放因子

特性：

- 当 $|\hat{y}| < \epsilon$ 时，奖惩被压缩
- 迫使模型输出明确的方向判断，而非保守的接近0预测

方案4：混合型GMADL（终极版）

结合方案1+2+3：

方向正确时：

$$L_i = -\alpha \cdot [\sigma(a \cdot y \cdot \hat{y}) - 0.5] \times |y|^b \times (1 + \lambda e^{-\beta|\hat{y}-y|}) \times \max(|\hat{y}|, \epsilon)$$

方向错误时：

$$L_i = \gamma \cdot [0.5 - \sigma(a \cdot y \cdot \hat{y})] \times |y|^b \times \max(|\hat{y}|, \epsilon)$$

推荐参数起点：

- $a=100, b=2$ （保持原值）
- $\alpha=1.0, \gamma=1.8$ （惩罚1.8倍于奖励）【为什么奖惩系数这样设置？】
- $\lambda=1.0, \beta=10$ （精度奖励翻倍，误差衰减快）
- $\epsilon=0.1$ （最小预测阈值10%）

六、验证计划

首先进行对照试验。将原有研究思路套用在这三种方案上进行小范围回测，依据结果再选合适模型进行真实数据下的训练。具体措施可拆分细化为下面三个部分：

6.1 理论验证

- ☐ 绘制改进GMADL的多子图线图，观察斜率变化
- ☐ 对比原GMADL vs 方案1/2/3/4的Loss曲线
- ☐ 检查梯度连续性和数值稳定性

6.2 实验验证

- ☐ 在合成数据集上对比原GMADL vs 改进版的模型收敛速度
- ☐ 在真实金融时序数据上回测交易策略表现（夏普比率、最大回撤）
- ☐ 敏感性分析：网格搜索最优超参数组合

6.3 消融实验

- ☐ 单独测试每个改进模块的贡献度
 - ☐ 确定哪些改进对最终性能影响最大
-

七、其他优化方向

方案5：动态权重型 (Dynamic Weighting)

针对问题4：极端惩罚饱和

方案5.1：软饱和和限制

$$L_i = -[\sigma(a \cdot y \cdot \hat{y}) - 0.5] \times \tanh(|y|^b)$$

核心思想：

- 用 $\tanh$ 函数替代直接的 $|y|^b$ ，限制极端惩罚上界
- 大波动时不会过度惩罚，避免模型过于保守

特性：

- $\tanh(x)$ 在 $x \rightarrow \infty$ 时渐近于1，提供自然上界
 - 保持小波动区域的原始特性
 - 平滑过渡，无需人工设定阈值
-

方案5.2：截断Loss

$$L_i = \max(\min(L_{original}, U), -U)$$

参数：

- U：Loss上界（建议0.3~0.5）

特性：

- 设置Loss的上下界 $\pm U$
 - 防止极端样本主导训练过程
 - 实现简单，但边界处不可导
-

方案6：自适应参数型 (Adaptive Parameters)

针对问题5：参数敏感性

方案6.1：波动率自适应sigmoid陡度

$$a(t) = \frac{a_0}{\sigma_{vol}(t) + \epsilon}$$

其中 $\sigma_{vol}(t)$ 为滚动窗口波动率估计。

核心思想：

- 根据滚动窗口波动率动态调整 a 参数
- 高波动期自动降低sigmoid陡度，避免饱和
- 低波动期提高敏感度，增强方向信号

特性：

- 无需手动调参
- 自动适应市场regime变化
- 建议窗口：20~60个交易日

代码实现：

```
def adaptive_a(returns, window=20, base_a=100, eps=1e-6):
    volatility = returns.rolling(window).std()
    return base_a / (volatility + eps)
```

方案6.2：学习率调度式参数衰减

$$a(t) = a_0 \cdot e^{-\lambda t}$$

参数：

- a_0 ：初始sigmoid陡度（建议100~200）
- λ ：衰减率（建议0.001~0.01）
- t ：训练步数

核心思想：

- 训练初期用大 a 强化方向信号，快速学习方向性
- 训练后期降低 a 提高稳定性，避免震荡
- 类似学习率退火策略

特性：

- 前期收敛快
- 后期稳定性好
- 适合端到端训练

方案7：梯度重塑型（Gradient Reshaping）

针对问题6：梯度不均匀

方案7.1：梯度裁剪+归一化

不改变Loss本身，而是在梯度层面优化：

$$g_{clipped} = \text{clip}(g, -c, c)$$

$$g_{norm} = \frac{g_{clipped}}{\text{std}(g_{clipped}) + \epsilon}$$

参数：

- c：裁剪阈值（建议0.5~2.0）
- ϵ ：数值稳定项（1e-6）

特性：

- 限制梯度范围，防止爆炸
- 标准化梯度，扩大有效区间
- 不改变Loss定义，兼容性强

方案7.2：对数缩放Loss

$$L_i^{new} = \text{sign}(L_i) \cdot \log(1 + |L_i|)$$

核心理想：

- 压缩大Loss值，放大小Loss值
- 使梯度分布更均匀
- 类似Huber Loss的思想

特性：

- 自动平衡不同量级的样本
- 提高训练稳定性
- 可能降低极端样本的学习效率

方案8：分段式设计（Piecewise Design）

综合优化：针对不同区域使用不同策略

方案8：三段式GMADL

$$L_i = \begin{cases} -\alpha \cdot [\sigma(a_1 \cdot y \cdot \hat{y}) - 0.5] \times |y|^b \times (1 + \lambda e^{-\beta|\hat{y}-y|}) & \text{if } |\hat{y} - y| < \delta_1 \\ -[\sigma(a_2 \cdot y \cdot \hat{y}) - 0.5] \times |y|^b & \text{if } \delta_1 \leq |\hat{y} - y| < \delta_2 \\ \gamma \cdot [0.5 - \sigma(a_3 \cdot y \cdot \hat{y})] \times |y|^b & \text{if } |\hat{y} - y| \geq \delta_2 \end{cases}$$

参数：

- δ_1 ：高精度阈值（建议0.05）
- δ_2 ：低精度阈值（建议0.3）
- a_1, a_2, a_3 ：不同区域的sigmoid陡度
- α ：高精度奖励系数（建议1.5）
- γ ：低精度惩罚系数（建议2.0）

核心思想：

- **高精度区**（误差<5%）：强奖励，鼓励精确预测
- **中等精度区**（5%~30%）：标准GMADL
- **低精度/方向错误区**（误差>30%）：强惩罚，避免大错

特性：

- 兼顾精度和方向
 - 自适应不同误差水平
 - 实现复杂，需要仔细调参
-

方案9：概率化改造（Probabilistic Extension）

引入不确定性建模

方案9：贝叶斯GMADL

假设预测分布 $\hat{y} \sim \mathcal{N}(\mu, \sigma^2)$ ：

$$L_i = \mathbb{E}_{\hat{y} \sim \mathcal{N}(\mu, \sigma^2)} [-[\sigma(a \cdot y \cdot \hat{y}) - 0.5] \times |y|^b] - \lambda \cdot H(\hat{y})$$

其中熵正则化项：

$$H(\hat{y}) = \frac{1}{2} \log(2\pi e \sigma^2)$$

核心思想：

- 第一项：期望Loss（对预测分布积分）
- 第二项：熵正则化（鼓励模型表达不确定性）
- 当模型不确定时，输出更大的 σ^2 ，降低Loss权重

特性：

- 提供预测置信度
- 对噪声数据更鲁棒
- 需要修改模型输出为分布参数

适用场景：

- 市场高度不确定时期
 - 需要风险评估的交易策略
 - 集成学习框架
-

方案10：时间序列特性融入（Temporal Awareness）

针对金融时序特性

方案10：趋势感知GMADL

$$L_i = -[\sigma(a \cdot y \cdot \hat{y}) - 0.5] \times |y|^b \times w_t$$

其中趋势权重：

$$w_t = 1 + \eta \cdot \text{momentum}_{t-k:t}$$

动量计算：

$$\text{momentum}_{t-k:t} = \frac{1}{k} \sum_{j=1}^k \text{sign}(y_{t-j})$$

参数：

- η ：趋势强度系数（建议0.2~0.5）
- k ：回溯窗口（建议5~20）

核心思想：

- 若过去 k 期趋势明确（momentum接近 ± 1 ），增大当前Loss权重
- 若过去震荡（momentum接近0），降低权重，容忍噪声
- 强化趋势跟踪能力

特性：

- 利用时序依赖性
- 适应趋势/震荡切换
- 融入领域知识

方案11：多目标联合优化（Multi-Objective）

同时优化方向性和其他指标

方案11：Pareto GMADL

$$L_{total} = \alpha \cdot L_{GMADL} + \beta \cdot L_{MSE} + \gamma \cdot L_{Sharpe}$$

其中Sharpe损失项（端到端优化）：

$$L_{Sharpe} = -\frac{\mathbb{E}[R_t - R_f]}{\sqrt{\text{Var}[R_t]}}$$

参数：

- α ：方向性权重（建议0.5~0.7）
- β ：精度权重（建议0.2~0.3）
- γ ：收益风险权重（建议0.1~0.2）

核心思想：

- 第一项：方向准确性（GMADL）

- 第二项：数值精度（MSE）
- 第三项：风险调整收益（直接优化交易目标）

特性：

- 端到端优化最终目标
- 平衡多个优化维度
- 需要在线回测反馈

实现挑战：

- Sharpe比率不可微，需要可微替代
- 权重需要动态调整
- 计算开销大

完整优化方案地图

方案编号	优化维度	针对问题	实现难度	预期效果	优先级
方案1	精度敏感	问题2	★☆☆	★★★	High
方案2	风险偏好	问题1	★☆☆	★★☆	High
方案3	置信度	问题3	★☆☆	★★☆	Medium
方案4	混合型	综合1+2+3	★★☆	★★★	High
方案5.1/5.2	饱和控制	问题4	★☆☆	★★☆	Medium
方案6.1/6.2	参数自适应	问题5	★★☆	★★★	High
方案7.1/7.2	梯度优化	问题6	★★☆	★★☆	Low
方案8	分段设计	综合	★★★	★★★	Medium
方案9	不确定性	鲁棒性	★★★	★★☆	Low
方案10	时序特性	领域知识	★★☆	★★★	Medium
方案11	多目标	端到端	★★★	★★★	Low